

컴퓨터비전과 기계학습

10주차 3차시

8장-기계 학습(1)

학습목차

- 기계 학습의 기초
- 지도 학습과 비지도 학습
- 재 샘플링을 이용한 성능평가
- 신경망

PREVIEW

■ 학습

- 사람의 가장 뛰어난 능력 (외부 환경이 사람을 지도)



그림 8-1 사람의 학습 과정

■ 기계 학습

- 기계도 학습을 할 수 있을까?
- 컴퓨터비전 분야에서 학습 목적은? 어떤 학습 모델이 있으며, 어떻게 학습할까?

각 절에서 다루는 내용

■ 기계 학습의 기초

기계 학습의 기초 원리에 대해 설명한다.

■ 신경망

퍼셉트론과 다층 퍼셉트론을 소개하고 최근 주목을 받는 깊은 학습도 설명한다.

■ SVM

여백을 최대화하는 원리를 사용하는 SVM에 대해 설명한다.

■ 분류기 앙상블

다수의 단순한 분류기를 결합하는 원리를 이용하는 에이더부스트와 임의 숲을 공부한다.

■ 기계 학습을 이용한 얼굴 검출

비올라-존스 얼굴 검출기를 포함하여 기계 학습으로 응용 문제를 해결한 사례를 소개한다.

8-1 기계 학습의 기초

8-1-1 지도 학습과 비지도 학습

8-1-2 재 샘플링을 이용한 성능평가

8-1 기계 학습의 기초

■ Mitchell의 정의

- “A computer program is said to learn from experience E with respect to some class of tasks T and performance measure P , if its performance at tasks in T , as measured by P , improves with experience E .

→ 어떤 컴퓨터 프로그램이 T 라는 작업을 수행한다. 이 프로그램의 성능을 P 라는 척도로 평가했을 때 경험 E 를 통해 성능이 개선된다면 이 프로그램은 학습을 한다고 말할 수 있다[Mitchell97, 2쪽].

■ 컴퓨터 비전에 대입하면

- T =분류(인식)
- E =학습 집합
- P =인식률

8-1-1 지도 학습과 비지도 학습

■ 사람과 기계의 학습 과정

- 학습 단계: 외부 지도에 따라 배우는 과정 (학습 집합 사용)
- 테스트 단계: 현장에서 성능을 평가 하는 과정 (테스트 집합 사용)



그림 8-2 사람과 기계의 학습 과정 비교

8-1-1 지도 학습과 비지도 학습

■ 지도 학습

- 부류 정보를 가진 샘플 (x, t) 로 구성된 학습 집합 사용
 - x 는 특징 벡터이고 t 는 x 가 속한 부류





그림 8-3 컴퓨터 비전에서 기계 학습

8-1-1 지도 학습과 비지도 학습

■ 학습 모델

■ 기계가 학습하려면 학습 모델 필요

- 학습 모델은 매개변수 집합 θ 로 표현됨 (예, 그림 8-3에서 θ 는 분할 경계선을 표현)
- 모델 선택이 필요하면 추가적으로 검증 집합 사용
- 학습의 목표는 최적의 θ 값을 찾는 것
 - θ 값이 얼마나 좋은지 측정하는 목적 함수 필요

■ 학습 알고리즘의 원리

- 학습 집합을 사용하여 현재 θ 값을 평가한 후, 개선하는 방향을 알아내 갱신
- 이런 과정을 수렴할 때까지 반복

8-1-1 지도 학습과 비지도 학습

■ 특징 추출은 어떻게 할까?



(a) 영역



(b) 이동 윈도우sliding window



(c) 관심점

그림 8-4 기계 학습에 사용할 특징 벡터를 수집하는 여러 가지 시나리오

8-1-1 지도 학습과 비지도 학습

■ 학습을 마친 분류기의 객관적 성능 평가

- 테스트 단계 → 학습 과정에서 사용하지 않은 테스트 집합으로 학습이 완료된 분류기 성능을 평가
- 학습 집합과 테스트 집합에 대한 성능이 비슷하면 일반화 능력이 뛰어남
- 우측은 좌측에 비하여 과적합
- 과적합 하면 일반화 능력이 떨어짐
- 일반화 능력이 우수한 방향의 분류기 지향
 - 신경망, SVM, AdaBoost, 임의숲




그림 8-5 오른쪽은 과적합 상황

8-1-1 지도 학습과 비지도 학습

■ 비지도학습과 준지도학습

■ 지도 학습에서 사용했던 $(\mathbf{x}, t)$ 중에 부류 정보 t 가 없는 상황의 학습

- ($\mathbf{x}$: 특징벡터, t : 그것이 속한 부류)

■ 비지도 학습

- 유사한 특징 벡터들을 끼리끼리 모으는 군집화 수행 (K-means, SVM 신경망, 민시프트 등의 군집화 알고리즘)
- 군집에서 유용한 정보 추출 (데이터 마이닝, 빅데이터, 정보 검색 등의 많은 응용)

8-1-1 지도 학습과 비지도 학습

■ 준지도 학습

- 부류 정보가 있는 샘플과 없는 샘플이 섞여 있는 상황의 학습
- 최근 중요성 부각
 - 아직 부류 정보를 부여하지 못한 샘플이 시시각각 인터넷에서 발생하기 때문
- 원리
 - 부류 정보가 있는 샘플로 학습한 후 부류 정보가 없는 샘플의 부류 정보를 추정
 - 추정된 정보로 반복 학습

8-1-2 재 샘플링을 이용한 성능 평가

- 학습에 사용할 데이터베이스가 작은 경우,
 - 기계학습은 학습집합으로 수행 → 학습이 완료되면 테스트 집합으로 성능평가
 - 기본 아이디어 : 같은 샘플을 여러 번 사용하여 성능 측정의 통계적 신뢰도를 높이려는 의도
- **k -겹 교차 검증 (k -fold cross validation)**
 - 샘플 집합을 k 개의 부분 집합으로 등분
 - $k-1$ 개의 부분 집합으로 학습에 사용하고
 - 나머지 하나를 테스트에 쓰는 과정을 k 번 반복
 - k 번 수행하여 얻은 성능의 평균값을 분류기의 성능으로 선택

알고리즘 8-1 교차 검증

입력 : $k(2 \leq k \leq N)$, 훈련 집합 $X = \{(x_1, t_1), (x_2, t_2), \dots, (x_N, t_N)\}$ 출력 : 성능 q

```
1   $X$ 를  $k$ 개의 부분 집합으로 등분하고 그들을  $X_1, X_2, \dots, X_k$ 라 한다.  
2  for( $i=1$  to  $k$ ) {  
3     $X' = \bigcup_{j=1, j \neq i}^k X_j$ 로 분류기를 학습시킨다.  
4     $X_i$ 로 분류기의 성능을 측정하여  $q_i$ 라 한다.  
5  }  
6   $q = (q_1 + \dots + q_k) / k$ ;
```


8-1-2 재 샘플링을 이용한 성능 평가

■ 붓스트랩

- 훈련 집합의 샘플링과 성능 측정을 여러 번 반복한 후, 평균 성능을 구함

알고리즘 8-2 붓스트랩

입력 : 훈련 집합 $X = \{(x_1, t_1), (x_2, t_2), \dots, (x_N, t_N)\}$, 샘플링 비율 $p (0 < p \leq 1)$, 반복 횟수 T

출력 : 성능 q

```

1  for( $t=1$  to  $T$ ) {
2       $X$ 에서 임의로  $pN$ 개의 샘플을 뽑아  $X_t$ 라 한다. 이때 대치를 허용한다.
3       $X_t$ 로 분류기를 학습시킨다.
4       $X - X_t$ 로 분류기의 성능을 측정하여  $q_t$ 라 한다.
5  }
6   $q = (q_1 + \dots + q_T) / T$ ;
```

8-2 신경망

8-2-1 구조와 작동 원리

8-2-2 학습

8-2-3 깊은 학습

8-2 신경망


■ 신경망은 연결주의 계산 모형

- 방대하게 연결된 많은 뉴런으로 구성된 뇌 구조를 모방한 계산 모형
- 1950년대 Rosenblatt의 퍼셉트론 → 선형 분류기에 불과
- 1980년대 퍼셉트론을 확장한 다층 퍼셉트론(MLP)
- 일반화 능력이 뛰어남

8-2-1 구조와 작동 원리

■ 퍼셉트론

- 입력은 특징 벡터 $\mathbf{x} = (x_1, x_2, \dots, x_d)$ $\rightarrow$ 1 값을 갖는 bias node 의 추가로 $d+1$ 개의 노드를 갖는다.
- 출력층 : 하나의 노드 y
- $\mathbf{x}$ 를 두 개의 부류 ω_1 과 ω_2 중의 하나로 분류하는 이진 분류기 $\rightarrow \omega_1 : 1$ 과 $\omega_2 : -1$



8-2-1 구조와 작동 원리

- 수식으로 쓰면,

- 출력 노드는 가중치 합과 활성화 함수 계산

- 특징 벡터 $\mathbf{x}=(x_1, x_2, \dots, x_d)$, 가중치 벡터 $\mathbf{w}=(w_1, w_2, \dots, w_d)$ 로 표기하면

$$y = \tau(s) = \tau\left(\sum_{i=1}^d w_i x_i + b\right) = \tau(\mathbf{w}\mathbf{x}^T + b)$$
$$\text{이때 } \tau(s) = \begin{cases} +1, & s \geq 0 \\ -1, & s < 0 \end{cases} \quad (8.1)$$

- 계단 함수 τ 를 활성화 함수로 사용

- 출력은 $+1(\omega_1$ 에 해당) 또는 $-1(\omega_2$ 에 해당) $\rightarrow$ 이진 분류기

8-2-1 구조와 작동 원리

예제 8-1 퍼셉트론의 동작 과정

2차원 공간 상에 [그림 8-7(a)]와 같이 네 개의 샘플 $\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3, \mathbf{x}_4$ 가 존재하며 $\mathbf{x}_2, \mathbf{x}_3, \mathbf{x}_4$ 는 ω_1 에 속하고 $\mathbf{x}_1$ 은 ω_2 에 속한다고 가정하자. 샘플과 부류를 값으로 표현하면 $\mathbf{x}_1 = (0,0), t_1 = -1, \mathbf{x}_2 = (1,0), t_2 = 1, \mathbf{x}_3 = (0,1), t_3 = 1, \mathbf{x}_4 = (1,1), t_4 = 1$ 이다. 이때 t_i 는 $\mathbf{x}_i$ 가 속하는 부류 정보로서, ω_1 에 속하면 1이고 ω_2 에 속하면 -1이다.




그림 8-7 퍼셉트론의 예

이 예제는 OR 게이트의 동작을 분류 문제로 간주한다. [그림 8-7(b)]는 이 분류 문제를 해결하는 퍼셉트론을 보여준다. 이 퍼셉트론은 $\mathbf{w} = (1,1), b = -0.5$ 를 가진다고 보면 된다. 네 개 샘플 중에 $\mathbf{x}_3 = (0,1)$ 을 입력해 보자.

$$y = \tau(\mathbf{w}\mathbf{x}_3^T + b) = \tau\left((1 \ 1)\begin{pmatrix} 0 \\ 1 \end{pmatrix} - 0.5\right) = \tau(0.5) = 1$$

출력으로 1을 얻었으므로 원하는 값 t_3 와 같다. 따라서 샘플 $\mathbf{x}_3$ 를 옳게 인식했다고 말할 수 있다. 나머지 샘플 세 개도 연필을 들고 계산하여 제대로 인식하는지 확인해 보자. 이 퍼셉트론은 [그림 8-7(c)]의 결정 직선에 해당하며 수식으로 표현하면 다음과 같다.

$$d(\mathbf{x}) = w_1x_1 + w_2x_2 + b = x_1 + x_2 - 0.5 = 0$$

8-2-1 구조와 작동 원리

■ 퍼셉트론의 한계

- 퍼셉트론은 식 (8.2)의 결정 초평면 역할을 하는 선형 분류기

$$\begin{aligned} d(\mathbf{x}) = \mathbf{w}\mathbf{x}^T + b \geq 0 &\text{이면 } \mathbf{x} \in \omega_1 \\ d(\mathbf{x}) = \mathbf{w}\mathbf{x}^T + b < 0 &\text{이면 } \mathbf{x} \in \omega_2 \end{aligned} \quad (8.2)$$

- 선형 분리 불가능한 상황에 대처하지 못함




그림 8-8 선형 분리 가능과 불가능

8-2-1 구조와 작동 원리

■ 다층 퍼셉트론으로 확장

- XOR 분류 문제: 퍼셉트론은 75% 정인식률이 한계
- 어떻게 100% 성능을 달성할 것인가? → 세 개의 퍼셉트론을 사용하여 해결
 - d_1 의 +영역과 d_2 의 +영역이 겹친 영역은 ω_1 , 나머지는 ω_2




그림 8-9 다층 퍼셉트론

첫 번째 단계에서 두 개의 퍼셉트론 d_1 과 d_2 를 이용하여 특징 벡터를 새로운 공간으로 매핑한 후, 새로운 공간에서 하나의 퍼셉트론 d_3 을 이용하여 최종 분류한 것